

「강화학습의 기초」 PROJECT
비트코인 거래 환경에서
강화학습 알고리즘 성능 비교



<https://github.com/ksc2507-cloud/btc-trading-rl.git>

서강대학교 AISW 대학원
A70040 김선천

“비트코인 트레이딩 환경에서 두 강화학습 알고리즘의 성능 비교 분석”

Reinforce

Policy-Based 알고리즘으로,
현재 상태에서 어떤 행동을 선택할 확률을
직접 학습

DQN

Value-Based 알고리즘으로,
각 행동의 가치를 나타내는 Q-value를 학습한 후
가장 가치가 높은 행동을 선택

데이터 수집 및 전처리

- 데이터 수집

구분	내용
데이터 출처	Yfinance(BTC-USD)
대상 데이터 기간	2020.01~2026.05
단위	일봉
총 데이터수	2,343일
Train Samples	2020.01.20~2024.12.31 (1,808일) 77.8%
Test Samples	2025.01.01~2026.05.30 (515일) 22.2%

- Feature Engineering

변수	계산식	의미	정규화(*)/처리
MA5	최근 5일 증가 평균	단기 추세	Rolling Mean(5)
MA20	최근 20일 증가평균	중기 추세	Rolling Mean(20)
MA Ratio	$(MA5 / MA20) - 1$	단기·중기추세차이	State 입력
RSI(14)	14일 상대강도지수	과매수·과매도	$RSI \div 100$ (*)
Price Change	$(Close_t - Close_{t-1}) / Close_{t-1}$	일간 수익률	$Clip(-1, 1)$ (*)
Volume Change	$(Volume_t - Volume_{t-1}) / Volume_{t-1}$	거래량 변화율	$Clip(-10, 10)$ (*)
Position	현재 보유 여부	보유 상태 정보	0 또는 1

환경 설계 (State, Action, Reward)

강화학습 에이전트가 BTC 시장에서 매매 결정을 학습하여 Buy & Hold 전략보다 높은 수익률 달성

• State

총 5개 변수로 상태 공간을 구성

- ✓ MA Ratio : 단기/중기 추세 차이
- ✓ RSI / 100 : 모멘텀 지표
- ✓ Price Change : 가격 변동률
- ✓ Volume Change : 거래량 변동률
- ✓ Position : 현재 보유 여부 (0 미보유/ 1보유)

• Action

1BTC단위의 거래 가정, 3 Actions

- ✓ 0 → Hold (관망)
- ✓ 1 → Buy (매수)
- ✓ 2 → Sell (매도)
- ※ Position 상태에 따라 일부 행동 제한
0 (미보유시) 가능행동은 Hold와 Buy
1 (보유시) 가능행동은 Hold와 Sell
- ※ 불가능한 행동 선택 시 Reward = -0.001

• Reward

실현 수익률 + 미실현 손익 반영 설계

- ✓ 보유 중 매 스텝 미실현 손익 $\times 0.1$ 반영
- ✓ Sell 시 수익률을 Reward로 부여
- ✓ 거래 수수료 0.1% 반영
- ※ 수익거래시 (+) 및 손실거래시 (-) reward, 불가능한 행동시 -0.001 페널티
- ※ 보유 중 가격 상승 시 소규모 (+) 및 하락 시 소규모 (-) reward
→ 에이전트가 가격 방향성을 매 스텝 인식

알고리즘 구현

두 알고리즘을 동일한 환경에서 비교하여 암호화폐 거래 성능을 분석

Reinforce

분류	Monte Carlo Policy Gradient
학습방식	에피소드 종료 후 정책 업데이트
출력	Buy/Hold/Sell 확률
탐색	확률 기반 샘플링+엔트로피 정규화(coef=0.01)로 과수렴 방지

DQN

분류	TD Learning (Off-policy)
학습방식	매 스텝마다 Q값 업데이트
출력	각 행동의 Q값
탐색	ϵ -Greedy / 에피소드 단위 선형 감소 (1.0 $\rightarrow$ 0.05, 전반 150 에피소드)

- ✓ 상태변수 5개를 입력받아 3개 행동 중 하나를 선택하도록 설계
- ✓ 미래 수익도 중요하게 고려하도록 할인율 $r=0.99$ 를 사용
- ✓ 학습 안정성을 위해 Adam Optimizer와 Gradient Clipping을 사용
- ✓ DQN은 Replay Buffer를 활용(과거 경험을 저장했다가 무작위로 재학습)하여 학습 안정성을 높임
- ✓ REINFORCE는 엔트로피 정규화를 추가하여 특정 행동으로의 과수렴을 방지
- ✓ DQN의 ϵ decay는 스텝 단위가 아닌 에피소드 단위로 적용 — 전반부 탐색, 후반부 활용이 실질적으로 분리됨

• Hyperparameter

	Reinforce	DQN
Episodes	300	300
Learning Rate	1e-3	1e-3
Gamma (γ)	0.99	0.99
Hidden Dim	64	64
Entropy Coef	0.01	-
Batch Size	-	64
Buffer Size	-	10,000
Target Update	-	10 ep마다
ϵ (start $\rightarrow$ end)	-	1.0 $\rightarrow$ 0.05
ϵ decay 방식	-	에피소드 단위 선형 감소

※볼드 표시된 에피소드수, 학습률, 할인률, 히든레이어수는 동일한 파라미터값 적용.

• Evaluation Metric

- ✓ Episode Total Profit : 에피소드 내 누적 실현 수익률 [핵심 성과 지표]
- ✓ Episode Reward : 누적reward합계(미실현손익포함) [학습 안정성 모니터링용]
- ✓ Buy & Hold : 단순 보유 전략 수익률 [기준선]

• 신뢰도 강화 방법

- ✓ Random seed 3개 (0, 1, 2) 반복 실험
- ✓ 평균 $\pm$ 표준편차로 신뢰구간 시각화
- ✓ Learning Rate Hyperparameter 3가지 비교 (1e-4 / 1e-3 / 5e-3)
- ✓ Buy & Hold를 baseline으로 비교
- ✓ ϵ decay 방식 수정 전후 비교 — 탐색 구간 정상화 효과 확인

실험 수정 및 결과 비교

초기 실험 결과 Reinforce는 테스트에서 거래 0회(수익률 0.00%), DQN은 Buy & Hold 하회(-26.66%, seed 편차 $\pm 15.68\%$)로 두 알고리즘 모두 기준선을 넘지 못하여, 일부 설계를 수정하여 실험을 진행함.

• 수정① Reward 재설계

- ✓ 이전 : 매도 시 실현수익률만 반영 → Hold 가 지배 전략으로 수렴
- ✓ 변경 : 보유 중 미실현 손익 $\times 0.1$ 을 매 스텝 추가 반영

• 수정② Reinforce 엔트로피 정규화

- ✓ 이전 : PG Loss만 사용 → Hold 확률 1.0으로 퇴화
- ✓ 변경 : 엔트로피 보너스 추가 (coef=0.01) → 행동 다양성 유지 강제

• 수정③ DQN ϵ decay 수정

- ✓ 이전 : 스텝마다 $\times 0.995$ → 에피소드 1개 만에 $\epsilon = 0.05$
- ✓ 변경 : 에피소드 단위 선형 감소 → 전반 150ep 탐색, 후반 활용

• [Test결과비교] Reinforce

	수정 전	수정 후
평균수익률	+0.00%	+18.46%
표준편차	$\pm 0.00\%$	$\pm 14.92\%$
거래횟수	0회	54~79회
B&H대비	+21.89%p	+40.35%p



• [Test결과비교] DQN

	수정 전	수정 후
평균수익률	-26.66%	-2.95%
표준편차	$\pm 15.68\%$	$\pm 3.59\%$
거래횟수	33~36회	37~44회
B&H대비	-4.77%p	+18.97%p

세 가지 수정 후 두 알고리즘 모두 Buy & Hold(-21.89%)를 상회
Reinforce는 거래 0회 문제 해소, DQN은 시드 간 편차 15.68% → 3.59%로 안정화

실험 결과 ① 학습 곡선 비교 (Train Samples)


DQN은 에피소드 150부터 Reward와 Profit이 급격히 상승하며 수렴하는 반면, Reinforce는 300 에피소드 내내 0.5~0.8 수준을 횡보
DQN의 신뢰구간은 에피소드 150 이후 크게 넓어지는데, seed별로 서로 다른 방향으로 특화되면서 편차가 커짐
두 알고리즘 모두 300 에피소드에서 완전히 수렴하지 않아 추가 학습 여지가 남아 있음



실험 결과 ② 수익률 비교 (Test Samples)

테스트 기간(2025~2026)은 BTC 하락장이었음

Reinforce는 +18.46%로 유일하게 양수 수익 달성, DQN은 B&H 대비 손실을 18.97%p 축소로 두 알고리즘 모두 단순 보유 전략을 상회함



- Reinforce

+18.46%

±14.92%/매매 54~79회

하락장에서 적극적 거래로 양수 수익 달성

- DQN

-2.92%

±3.59%/매매 37~44회

Buy&Hold 대비 손실 18.97%p 축소

- Buy&Hold

-21.89%

기준선/매매 1회

Test구간이 비트코인 하락장 구간으로 손실

실험 결과 ③ 거래 패턴 비교

Reinforce +29.87% vs DQN -3.77%의 차이는 거래 횟수가 아니라 매도 타이밍에서 갈림
Reinforce는 고점 근처에서 매도를 실행했고, DQN은 매수 편향으로 포지션을 쌓다가 하락을 그대로 맞음



- Reinforce

- ✓ 매수/매도 균형이 잡혀 있음. (매수 141회/매도 178회)
- ✓ 확률 분포로 행동을 선택하기 때문에 시장 흐름에 따라 유연하게 반응

응



- DQN

- ✓ 매수와 매도 횟수가 크게 불균형 (매수 131회/매도 76회)
- ✓ 매수 Q값이 과도하게 높게 학습되어 매도 타이밍을 놓치는 패턴 반복

복

실험 결과 ④ DQN 하이퍼파라미터 조정 – Learning Rate

민감도 분석 결과 lr 0.005는 발산, 0.0001~0.001은 안정적으로 수렴함을 확인
0.0001과 0.001 사이에서는 유의미한 차이가 없어 이 범위 안에서는 학습률이 크게 민감하지 않음



- **목표달성여부**

- ✓ 하락장(2025~2026) 테스트 환경에서 Reinforce, DQN 두 알고리즘 모두 Buy & Hold(-21.89%)를 상회함
- ✓ Reinforce +18.46%, DQN -2.92%로 강화학습 기반 트레이딩 에이전트가 단순 보유 전략 대비 유효함을 확인

- **알고리즘별 특성**

- ✓ Reinforce는 높은 기대수익(+18.46%)을 달성했으나 seed 간 편차($\pm 14.92\%$)가 커 결과의 일관성이 낮음. (안정성 측면 한계)
- ✓ DQN은 수익률(-2.92%)은 낮지만 시드 간 편차가 $\pm 3.59\%$ 로 매우 안정적

- **한계점 및 향후 과제**

- ✓ 두 알고리즘 모두 300 에피소드에서 완전히 수렴하지 않았고, seed 3개라는 제한된 표본으로 일반화에는 주의가 필요
- ✓ 향후 에피소드 수 확대, Reward 정교화, Train/Test 구간 다변화를 통해 일반화 성능을 검증할 필요 있음

